المعهد العالي للإعلامية بالكاف
Institut Supérieur d'Informatique du KEF

جامعة جندوبة
Université de Jendouba

CyberCloud SOLUTIONS

PROJET DE FIN D'ÉTUDES · MASTÈRE PROFESSIONNEL — APPLICATIONS WEB INTELLIGENTES

Conception et développement d'une plateforme intelligente d'aide au recrutement et de mise en correspondance entre CV et offres d'emploi

JobTest | Moteur hybride | Explicable | Décision humaine

PRÉSENTÉ PAR
Iheb El Ech

ENCADRANT ACADÉMIQUE
Dr. Aymen Louati

ENCADRANTE PROFESSIONNELLE
Dr. Emna Trabelsi

ORGANISME D'ACCUEIL
CyberCloud Solutions

Institut Supérieur d'Informatique du Kef — Université de Jendouba

SOUTENU LE JJ / MM / 2026

Année universitaire 2025–2026

— PLAN DE LA PRÉSENTATION

Sommaire

I — **Contexte**
Entreprise · Existant · Problématique

II — **Méthodologie**
Modèle en cascade

III — **Besoins**
Acteurs · BF · BNF · Règles

IV — **Conception**
UML · Séquences · Architecture

V — **Moteur intelligent**
TF–IDF · Embeddings · Compétences

VI — **Réalisation & Déploiement**
Stack · Démo · Tests · Azure

✓ — **Conclusion**
Apports · Limites · Perspectives

— INTRODUCTION

« Trier des CV coûte du temps. Décider reste humain. »

PDF · DOCX · TXT

CV hétérogènes

Langage libre

Offres d'emploi

3

signaux fusionnés

0

décision automatisée

Assister le recruteur, pas le remplacer.

Organisme d’accueil : CyberCloud Solutions

CyberCloud SOLUTIONS

Services & conseil en informatique

Fondée en 2017 | Grand Tunis | 2–10 personnes

ACTIVITÉS & DOMAINES D'EXPERTISE

- Conseil & transformation numérique
- Infrastructure : serveurs, stockage, postes
- Sécurité Internet, network forensics
- Cybersécurité, XDR, Cloud, DevOps

Cadre du stage

- PFE individuel
- Mars → août 2026
- Mode distant / hybride
- Sujet proposé par l'entreprise

Étude de l'existant : deux approches, deux limites

① Processus manuel

01 Lire l'offre → 02 Définir critères → 03 Ouvrir les CV → 04 Repérer compétences → 05 Garder / écarter

- Coûteux à répéter
- Peu traçable
- Formats disparates

② ATS & approches lexicales

- Recherche par mots-clés
- Filtres & champs structurés

- Paraphrases ignorées
- CV multilingues
- Vocabulaire non identique

Benchmark des solutions : où se situe JobTest

CRITÈRE	LINKEDIN RECRUITER	WORKABLE	GREENHOUSE	JOBTEST
Correspondance CV/offre	Recherche IA + recommandations	Tri *best match*	Talent Matching pondéré	**Hybride : lexical + sémantique + compétences**
Éléments explicatifs	Synthèse IA, granularité non doc.	Score IA non décomposé	Scorecards	**Sous-scores + écarts + recommandations**
Analyse des écarts de compétences	Non documenté	Non documenté	Non documenté	**Trouvées / manquantes / critiques**
Classement & export	Export non documenté	Export non documenté	Rapport XLS	**Multi-CV + historique + rapport PDF**
Contrôle & données	Non documenté	Doc. sécurité générique	Non documenté	**Cloisonnement par recruteur, VM Azure**

« non documenté » = aucune preuve dans les pages officielles consultées (13/09/2026)

Critique de l’existant : le vrai manque



TROIS BRIQUES SOUVENT SÉPARÉES

Analyse
Le texte est comparé

Décision
Une règle tranche

Explication
Une justification s'affiche

⚠ **Le manque : leur cohérence**

PROBLÉMATIQUE

Comment fournir au recruteur une évaluation CV/offre à la fois hybride, explicable, reproductible et persistante — sans lui déléguer la décision d'embauche ?

Contenu hétérogène

Vérifiable par ses composantes

Reproductible

Génératif encadré

Solution proposée : JobTest

CV
texte · PDF · DOCX

Offre d'emploi
description + compétences

MOTEUR HYBRIDE

TF-IDF

Embeddings

Compétences

Score global %
0 → 100

Verdict
HIRE · CONSIDER · REJECT

Compétences
trouvées / manquantes

Recommandations
actions prioritaires

Historique · Classement multi-CV · Rapport PDF · AI Insights · AI Quality Center

Objectifs du projet : 8 engagements

Workflow recruteur
OBJ-01

CV texte ou fichier
OBJ-02

3 signaux fusionnés
OBJ-03

Décision cohérente
OBJ-04

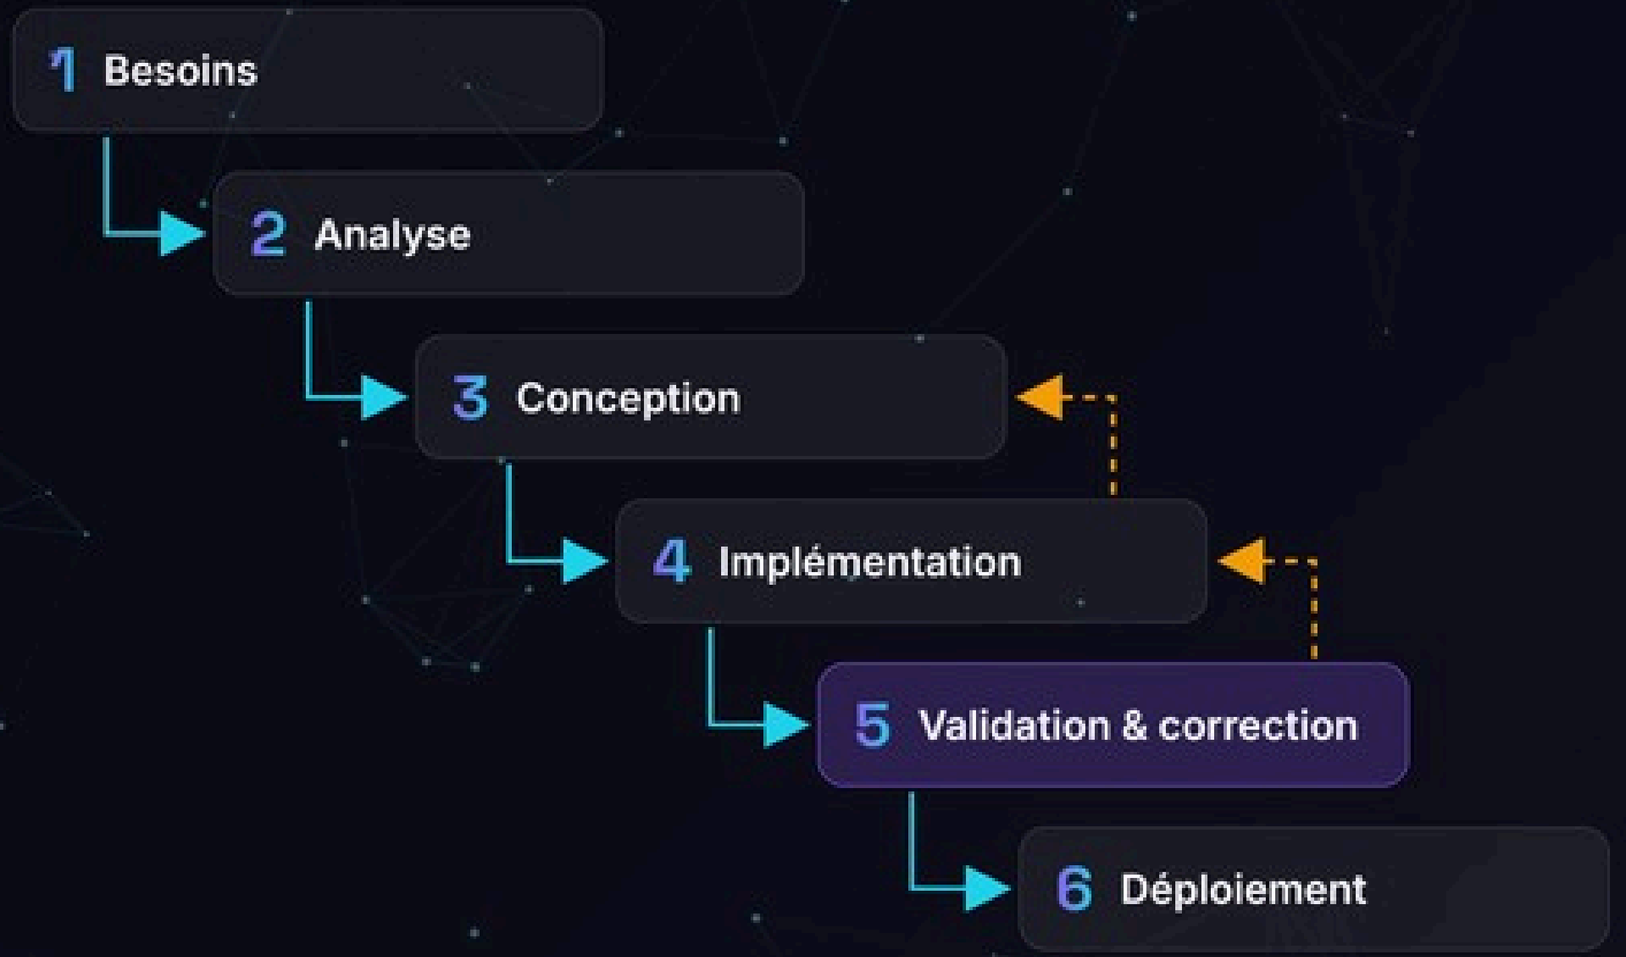
Résultat explicable
OBJ-05

Historique persistant
OBJ-06

Rapport + classement
OBJ-07

Déploiement démontrable
OBJ-08

Modèle en cascade avec retours de correction



POURQUOI CE MODÈLE

- **Livrables stabilisés**
- **Fil de lecture clair**
- **Boucles de correction assumées**

- - - - · retours de correction

Royce (1970) : cascade avec retours contrôlés

Acteurs et parties prenantes

Visiteur
non authentifié

Recruteur
authentifié
acteur principal

SYSTÈME JOBTEST

Créer un compte
Se connecter

FONCTIONS MÉTIER

Offres
Candidats
Évaluation
Analyse approfondie
Rapport PDF
Classement
Historique
Seuils

Candidat
entité métier, jamais utilisateur

Maintenance / QA
partie prenante technique
hors parcours

Besoins fonctionnels : 6 familles

AUTH

BF-AUTH-01→03

- Inscription
- Login JWT
- Déconnexion

OFFRES

BF-JOB-01→04

- CRUD complet
- `OPEN` / `ON_HOLD` / `CLOSED`
- Code auto `JOB-YYYY-NNN`

CANDIDATS

BF-CAND-01→03

- Liste par recruteur
- Pipeline : `NEW` → `UNDER_REVIEW` → `SHORTLISTED` → `INTERVIEW` → `HIRED` / `REJECTED`

ÉVALUATION

BF-EVAL-01→03

- Texte ou PDF/DOCX
- Verdict explicable
- Résultat persisté

COMPLÉMENTS

BF-LLM-01 · BF-REPORT-01 · BF-RANK-01/02

- Analyse approfondie
- Rapport PDF
- Classement + CSV

PILOTAGE

BF-HIST-01 · BF-QUALITY-01/02 · BF-SETTINGS-01

- Historique
- AI Insights · Quality Center
- Seuils réglables

Besoins non fonctionnels (ISO/IEC 25010)

BNF-SEC

Sécurité

JWT + appartenance

BNF-PRIV

Confidentialité

Cloisonnement par recruteur

BNF-EXPL

Explicabilité

Même politique partout

BNF-REPRO

Reproductibilité

Poids & seuils persistés

BNF-PERF

Performance

Layer 2 non bloquante (~54 s CPU)

BNF-RES

Fiabilité

Ollama indisponible ≠ échec

BNF-ERG

Ergonomie

Responsive + `prefers-reduced-motion`

BNF-PORT

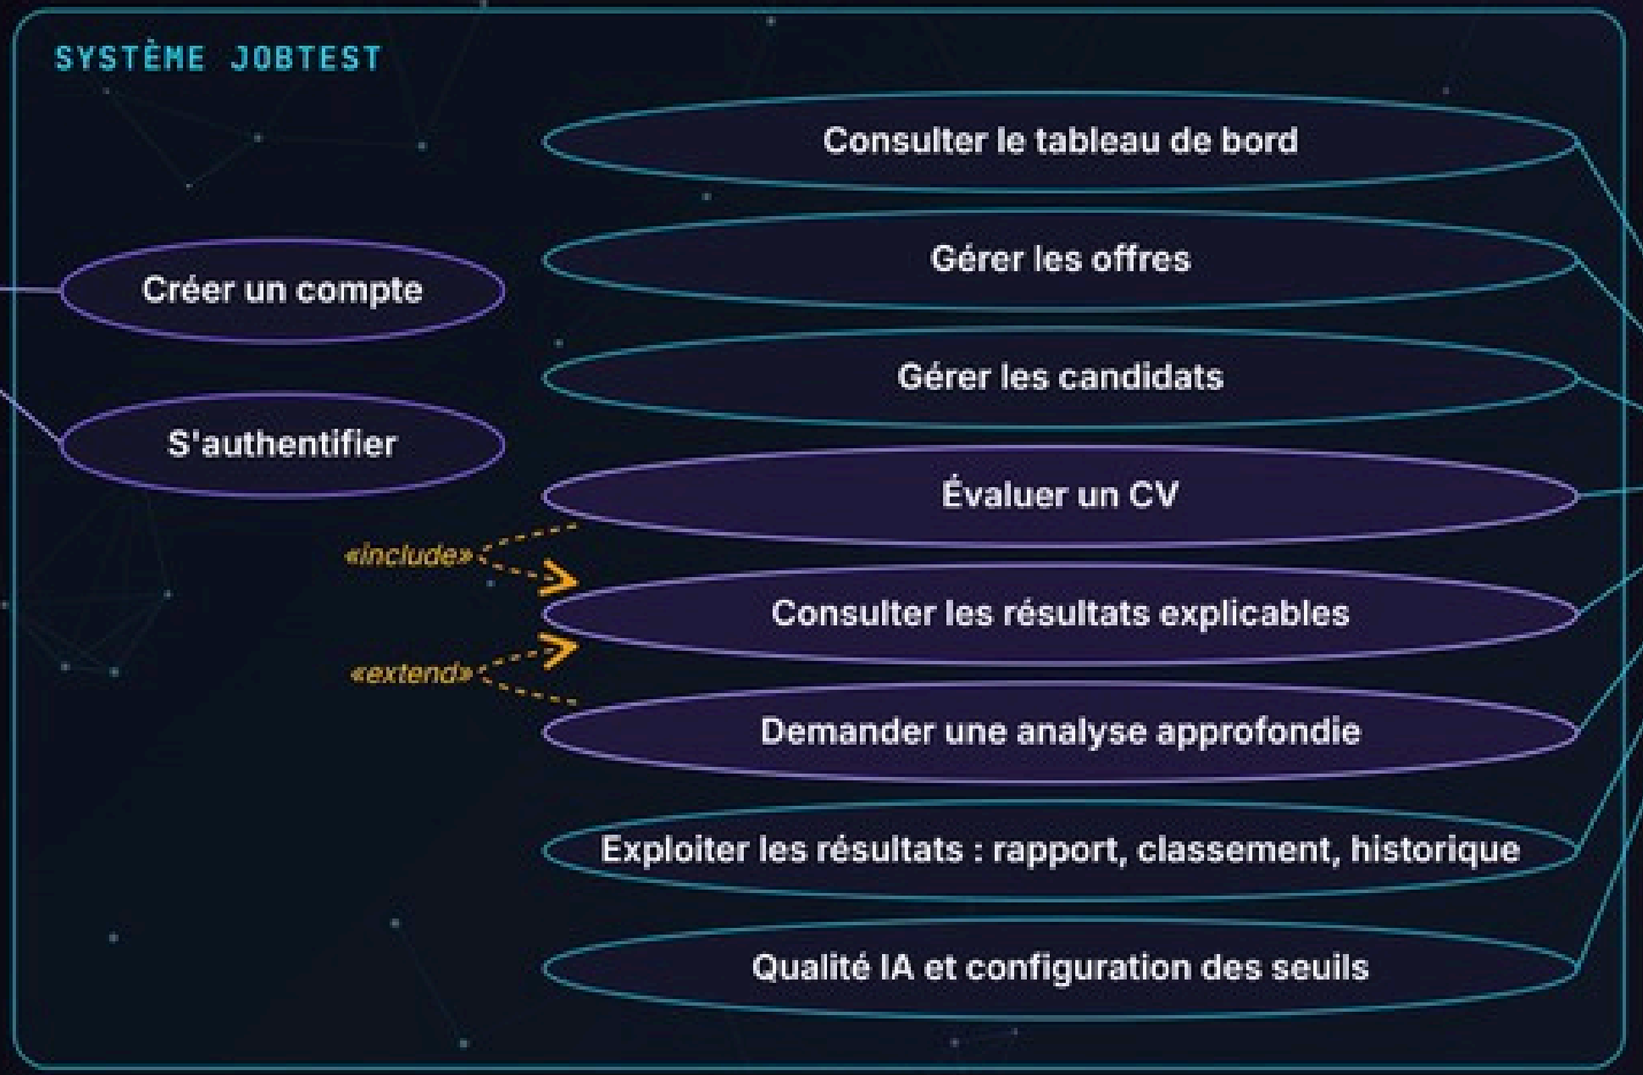
Portabilité

Docker Compose

Règles de gestion : RG-01 → RG-10

RG-01	Un recruteur ne voit que ses données
RG-02	Offre évaluée → non supprimable
RG-03	Candidat évalué → non supprimable
RG-04	Décision selon seuils actifs
RG-05	`Potential Fit < Strong Fit`
RG-06	**La couche LLM ne modifie JAMAIS le score ni le verdict**
RG-07	AI Insights ne persiste rien
RG-08	Deep Analysis persistée seulement si `ok`
RG-09	L'historique garde ses métadonnées
RG-10	Uploads : PDF/DOCX avec texte lisible

Diagramme global des cas d'utilisation



Cas d’utilisation raffinés : UC-01 → UC-08

UC-01

Authentification

- Créer un compte
- Se connecter (JWT)
- Fermer la session

UC-02

Offres

- Créer / modifier
- Clôturer / rouvrir
- Supprimer si non évaluée

UC-03

Candidats

- Lister ses candidats
- Mettre à jour le statut
- Supprimer si non évalué

UC-04

Évaluer un CV

- Choisir une offre
- Texte ou PDF/DOCX
- Verdict persisté

UC-05 «extend»

Analyse approfondie

- Contexte du résultat
- Appel Ollama local
- Persistée si ok

UC-06

Rapport PDF

- Exporter le résultat
- Génération ReportLab
- Aucun recalcul

UC-07

Classement multi-CV

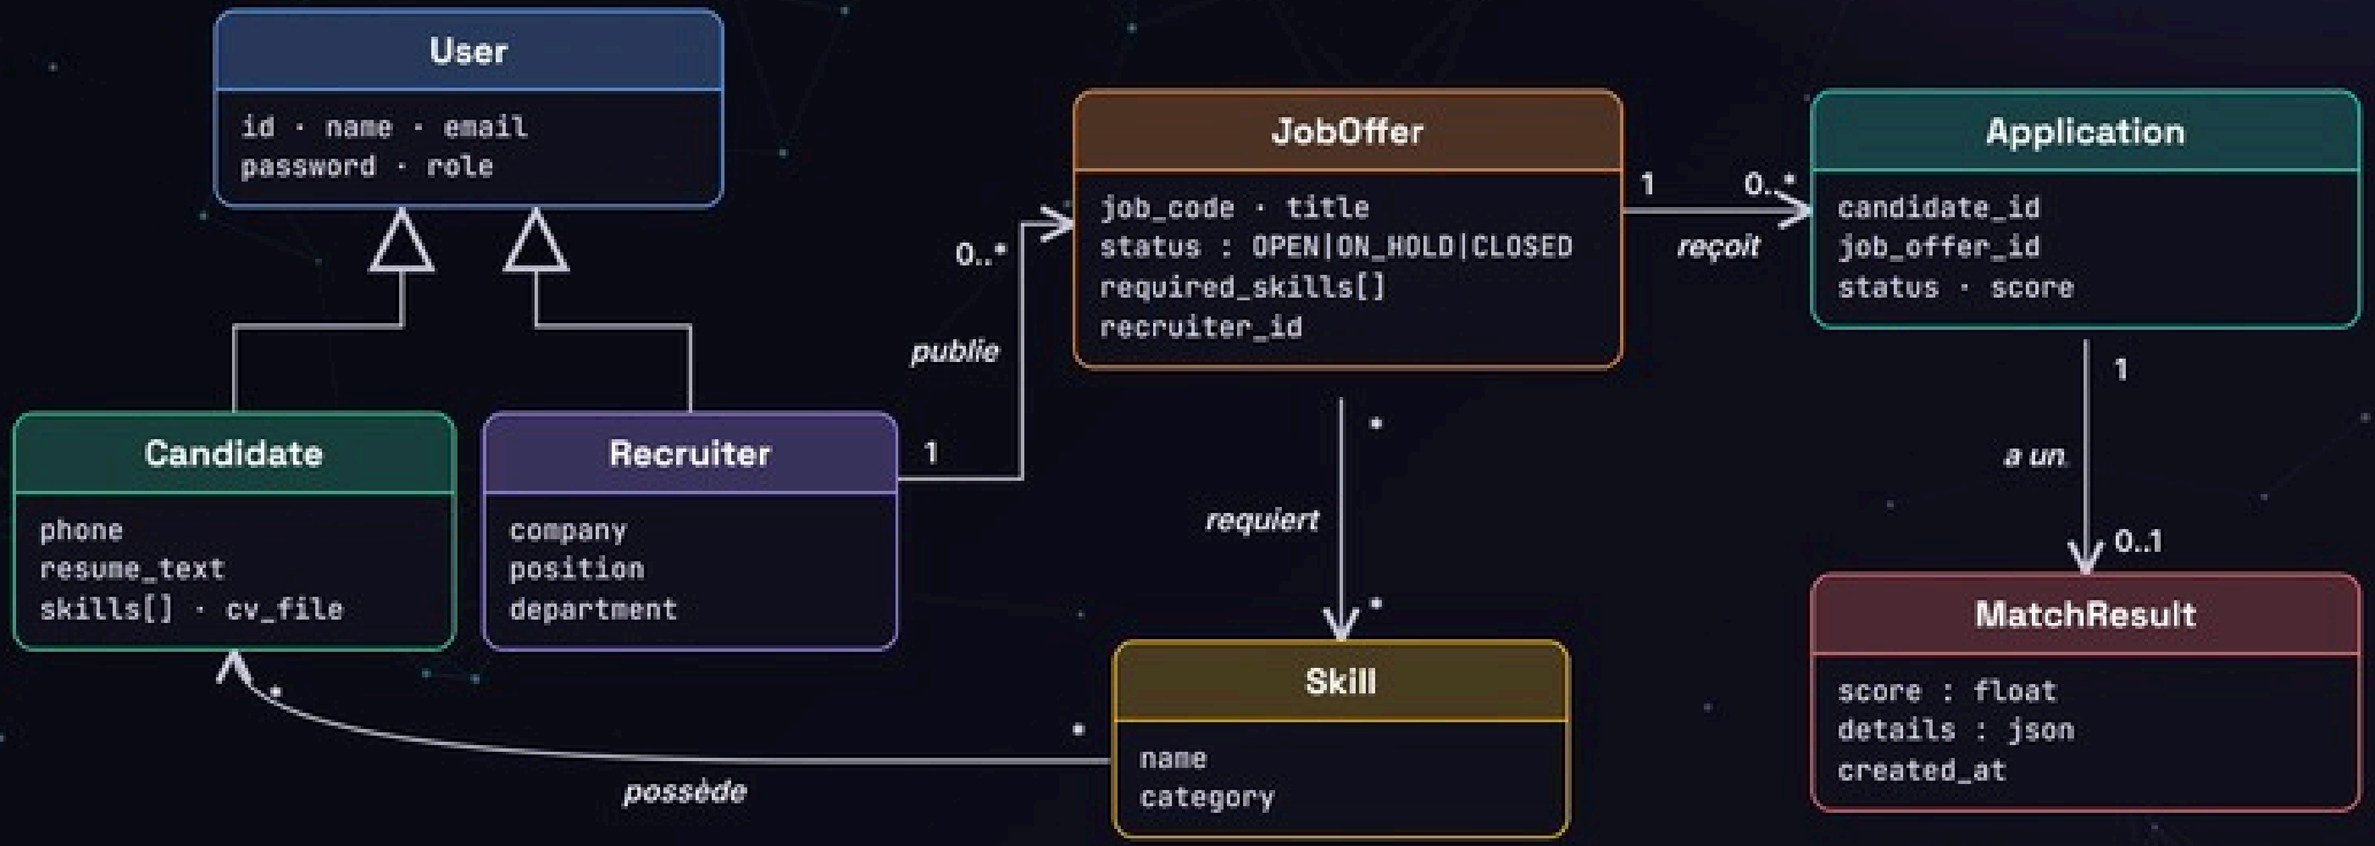
- Une offre, plusieurs CV
- Tri par score
- Export CSV

UC-08

Historique

- Liste par date
- Filtres multicritères
- Détail vérifié

Diagramme de classes : le modèle métier

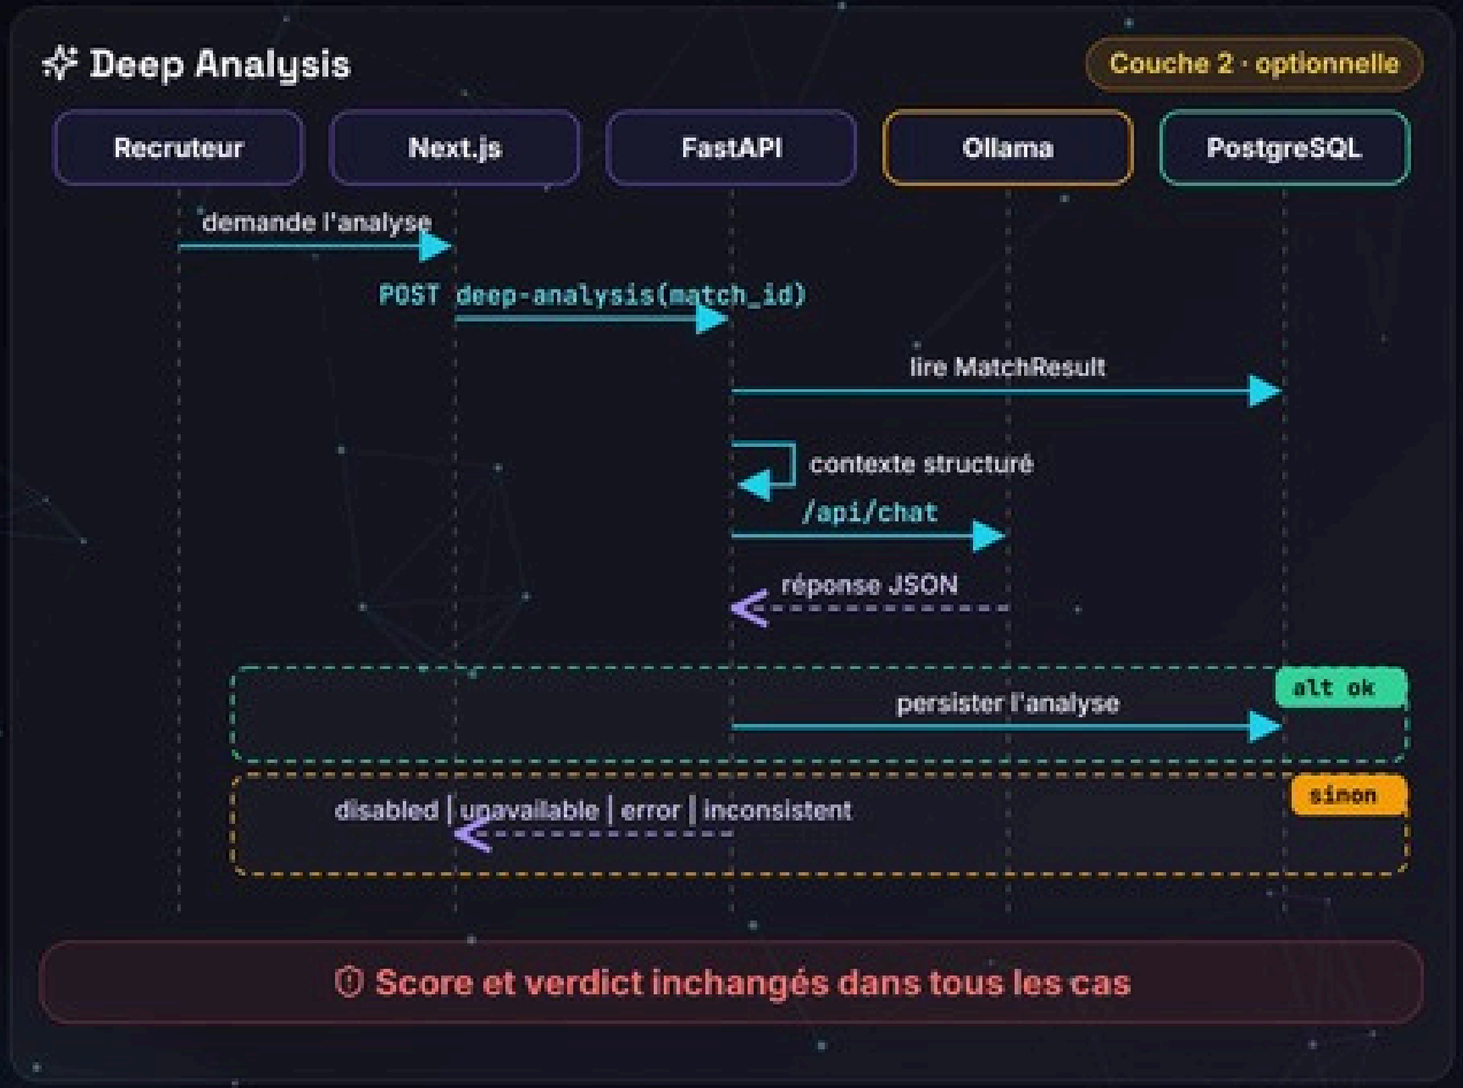


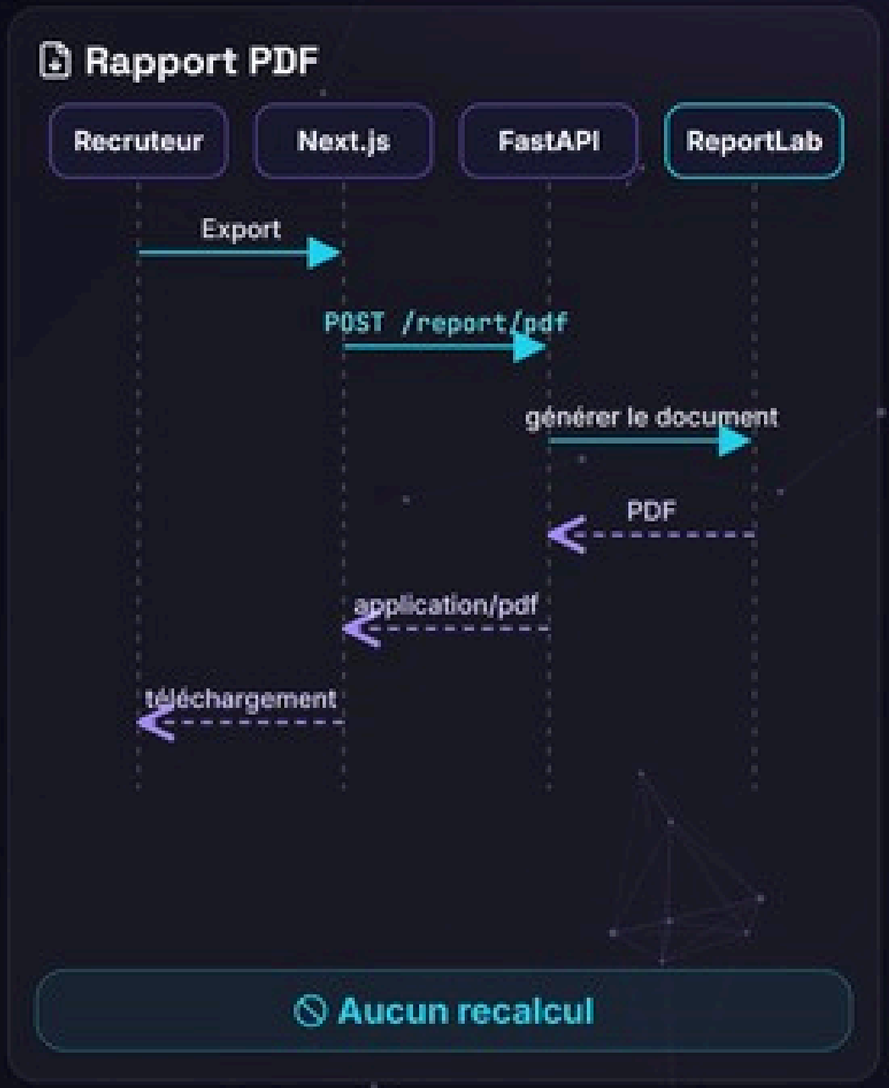
`llm_analysis_json` stocké **dans** MatchResult — pas de table dédiée

Séquence : évaluation d'un CV — le flux central

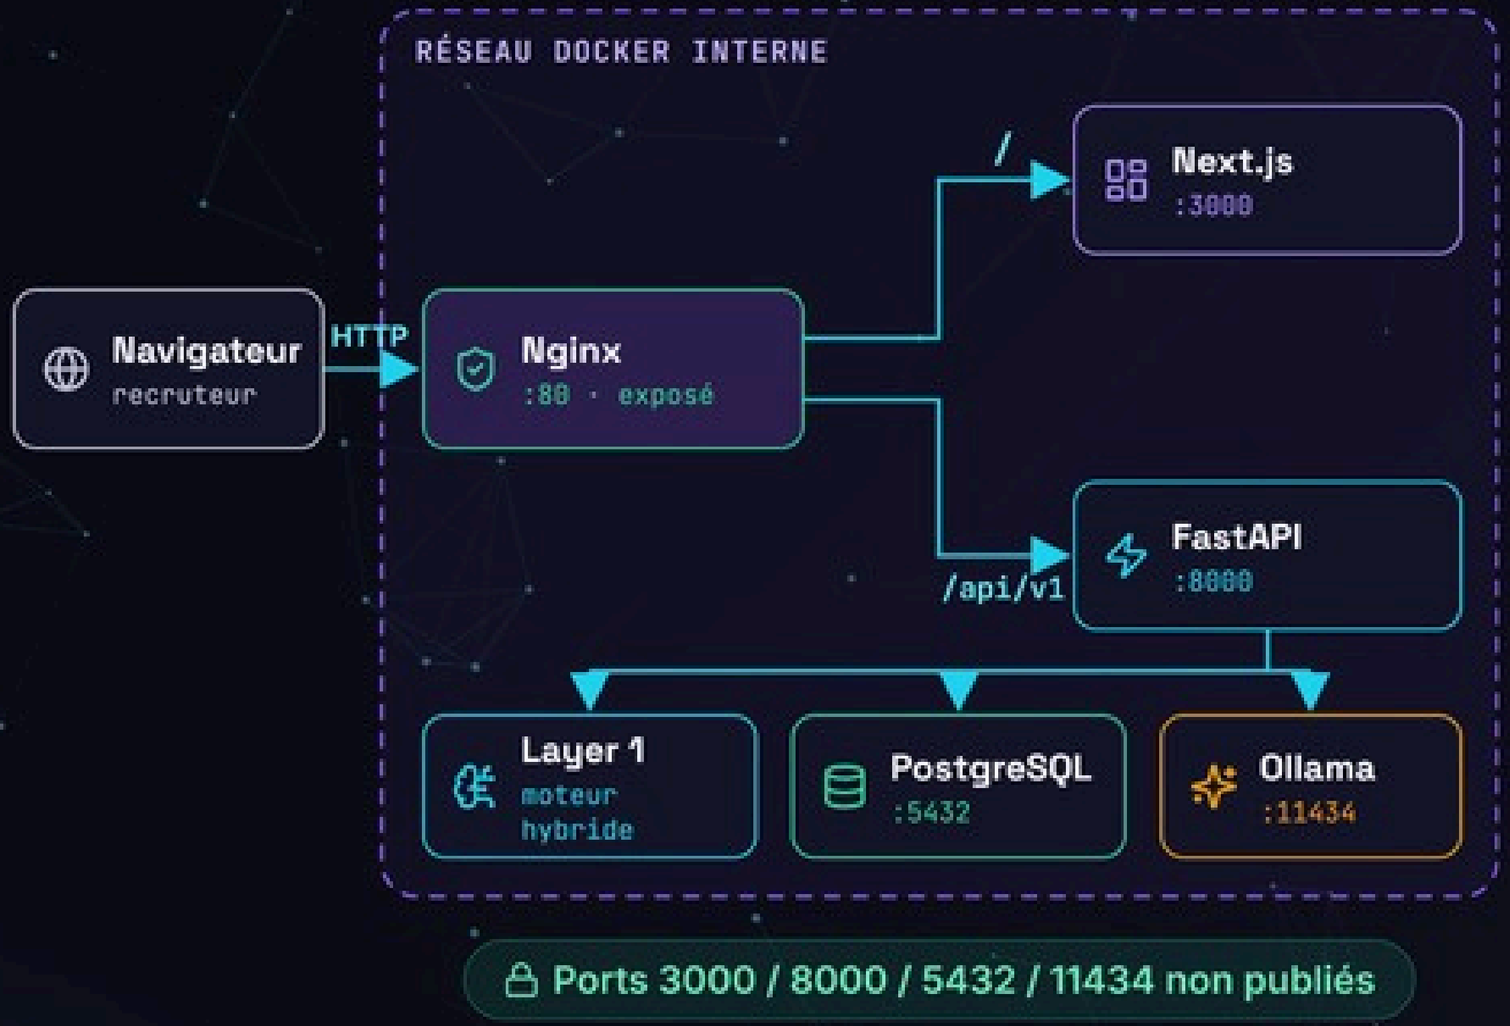


Séquences : analyse approfondie + rapport PDF





Architecture logique : un seul point d'entrée



Modules & responsabilités

web/	UI
src/api/	HTTP + JWT
src/matching/	orchestration
src/models|fusion/	scores
src/explainability/	explications
src/ai/	Ollama
src/reporting/	PDF
src/models_db.py	ORM

Pipeline de rapprochement : du document à la décision



Couche 2 optionnelle
analyse locale & questions d'entretien

additive, non décisionnelle

Les 3 composantes du score

① LEXICAL
TF-IDF

$$S_{TFIDF} = \cos(v_{CV}, v_{offre})$$

- n-grammes 1–3
- 10 000 features max
- Similarité cosinus

⚠ Sensible aux synonymes

② SÉMANTIQUE
Embeddings

$$S_{emb} = 0{,}7 \cdot \text{moy}(en, multi) + 0{,}3 \cdot \text{sections}$$

all-mpnet-base-v2
paraphrase-multilingual-mpnet-base-v2
repli : HashingVectorizer

PONDÉRATION PAR SECTIONS



③ COMPÉTENCES
Dictionnaire versionné

techniques 0,70 · comportementales 0,30

+ +0,05 bonus domaine

+ ≤ +0,10 certifications

− ≤ −0,20 critiques absentes

Trouvées · manquantes · critiques

Fusion hybride & décision

$$S_{hybride} = 0{,}2 \cdot S_{TFIDF} + 0{,}4 \cdot S_{emb} + 0{,}4 \cdot S_{skill}$$

[75 - 100]	HIRE	*adéquation forte, à examiner en priorité*
[55 - 75[	CONSIDER	*à examiner avec réserves*
[0 - 55[	REJECT	*adéquation insuffisante*

Seuils réglables par le recruteur et enregistrés avec chaque résultat

Couche 2 : analyse locale encadrée

LAYER 1
Déterministe

→ SCORE + VERDICT

RG-06

LAYER 2 · OLLAMA
qwen2.5:1.5b

trajectoire | alertes | justification | recommandations | questions d'entretien

3 GARDE-FOUS

Format imposé

- Aucun champ de score
- Réponse non conforme = rejetée

Contrôle de cohérence

- Trop favorable sur un `REJECT`
- Relance, puis `inconsistent`

Anti-injection de prompt

- Score calculé **avant** le modèle
- Injection ⇒ commentaire seulement

ÉTATS POSSIBLES ok | disabled | unavailable | error | inconsistent

Protocole expérimental : données & partition

cv_job_dataset.csv

graine 42

12 000 paires CV–offre

20 domaines métier

FR + EN

abréviations

fautes de frappe

technologies obsolètes

paires contradictoires

PARTITION STRATIFIÉE

8 400 train	1 800 validation	1 800 test

Pourquoi un corpus synthétique

- Aucun corpus réel accessible
- Contrainte juridique & éthique
- Qualité d'extraction maîtrisée
- Pas de vérité terrain réelle
- Reproductible (graine fixée)

Résultats comparatifs : F1 0,93 · AUC 0,96 pour l'hybride

MÉTHODE	SEUIL	EXACT.	PRÉC.	RAPPEL	F1	AUC-ROC
TF-IDF	0,04	0,93	0,93	0,97	**0,95**	**0,98**
Embeddings	0,54	0,78	0,81	0,89	0,85	0,81
Compétences	0,00	0,89	0,89	0,97	0,93	0,95
Hybride	0,26	0,91	0,94	0,93	**0,93**	**0,96**

FUSION
55,85 ms / paire

EMBEDDINGS SEULS
921,60 ms / paire



ⓘ *Le générateur partage un vocabulaire contrôlé → avantage mécanique du lexical*

Honnêteté scientifique : deux corrections assumées

① Poids du moteur

HÉRITÉ · GRID SEARCH
0,9 / 0,0 / 0,1

→

RÉTABLI · DOCUMENTÉ
0,2 / 0,4 / 0,4

MÊME PROFIL, COMPÉTENCES IDENTIQUES

POIDS	CV CALQUÉ	CV REFORMULÉ	ÉCART
0,9/0,0/0,1	99,2 %	73,6 %	25,6 pts · faille
0,2/0,4/0,4	94,4 %	84,8 %	9,6 pts · sain

Recopier l'annonce ne rapporte plus 25 points.

② Protocole d'évaluation

SEUIL UNIQUE
0,60 partout

→

SUR LA VALIDATION
calibré / méthode

EXEMPLE : TF-IDF

0,000
F1 avant

→

0,950
F1 après

= AUC inchangée : 0,979

Alerte auto si AUC ≥ 0,80 et F1 ≤ 0,05

Stack technique complète

Frontend	Next.js 14.2.35 · App Router · React 18 · TypeScript
Style & animation	Tailwind CSS · Framer Motion · Three.js / react-three-fiber
Backend	Python · FastAPI · Uvicorn (ASGI) · Pydantic
Persistance	SQLAlchemy · SQLite (dev) · PostgreSQL 16
IA	scikit-learn · Sentence-Transformers · spaCy · Ollama · qwen2.5:1.5b
Documents	pdfplumber + PyPDF2 · python-docx · ReportLab
Infra	Docker Compose · Nginx · Microsoft Azure

Architecture du projet : qui fait quoi

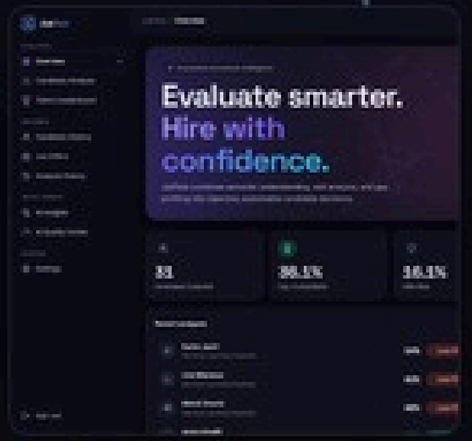
`web/`	Pages Next.js, composants, client API	`src/explainability/`	Explications
`src/api/`	FastAPI, routeurs auth + ui	`src/ai/`	Prompts Ollama
`src/matching/`	Évaluation & persistance	`src/parsing/`	Extraction PDF / DOCX
`src/models/`	TF-IDF, embeddings, compétences	`src/reporting/`	ReportLab
`src/fusion/`	Score hybride	`deploy/nginx/`	Relais HTTP
`src/decisioning/`	Règles de verdict		

Une responsabilité par dossier

Les interfaces : captures réelles de la plateforme



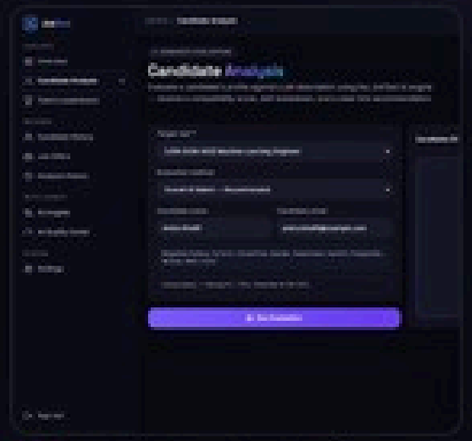
01 Login



02 Overview



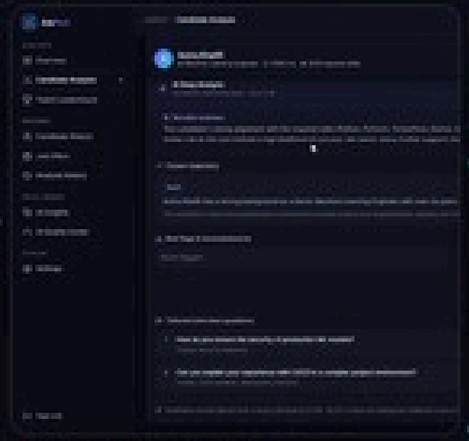
03 Job Offers



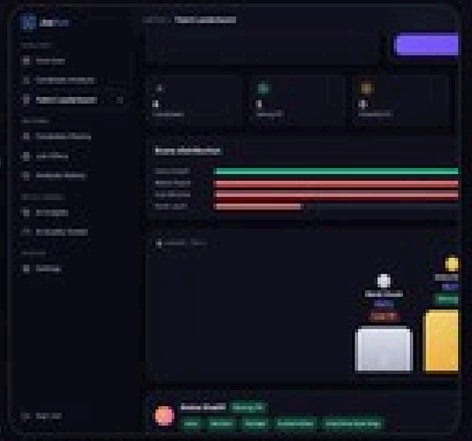
04 Candidate Analysis



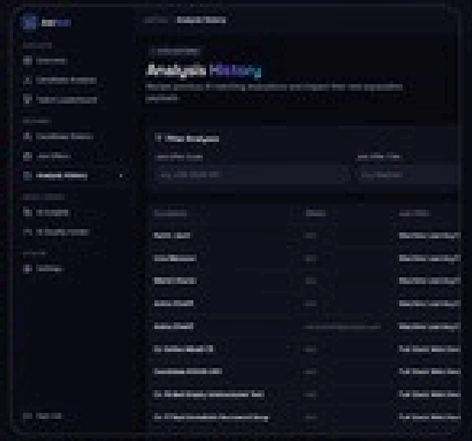
05 Résultat & radar



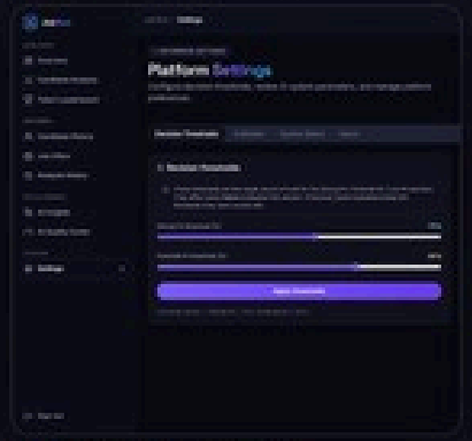
06 Deep Analysis



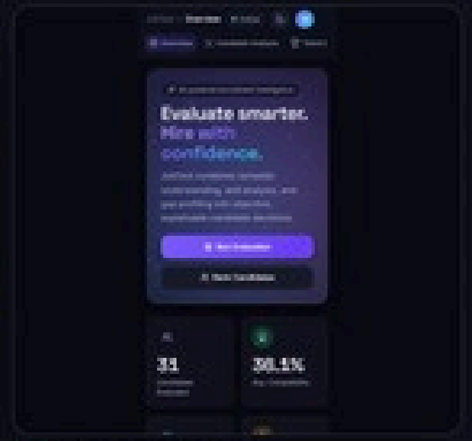
07 Leaderboard · podium



08 Analysis History



09 Settings · seuils



10 Vue mobile

Interface responsive, vérifiée sur mobile

DÉMONSTRATION

DÉMO EN LIGNE

http://20.51.167.202/

1. Connexion → 2 Créer une offre → 3 Évaluer un CV → 4 Lire le résultat → 5 Analyse approfondie → 6 Export PDF



EMPLACEMENT VIDÉO

Enregistrement complet de la plateforme

Tests & validation : ce qui est prouvé

Suite de tests

pytest · ~45 s

106 / 113 réussis

✕ 6 échecs · test_api_extended.py

— 1 ignoré

- Fixtures antérieures au contrôle d'appartenance
- 404 attendu, test à mettre à jour

⚠ Suite non entièrement verte, maintenance identifiée

Bout en bout sur Azure

✓ F01 → F08 OK

- F01 Inscription
- F02 Login
- F03 Refus d'identifiants
- F04 Création d'offre
- F05 Évaluation · CONSIDER
- F06 Persistance
- F07 Deep Analysis ok
- F08 PDF 1.4 · 2 pages

5 conteneurs healthy · ✓ nginx -t OK · Swagger accessible

PDF : 112 039 octets

Sécurité & données personnelles : acquis et limites

Mis en œuvre

- ✓ bcrypt (passlib)
- ✓ JWT HS256 + expiration
- ✓ `_assert_owned` par ressource
- ✓ Cloisonnement `recruiter_id`
- ✓ ORM SQLAlchemy, pas de SQL concaténé
- ✓ 60 req / min / IP
- ✓ Corps limité à 15 Mo
- ✓ Secrets hors dépôt · `.env` 0600
- ✓ NSG Azure : TCP 80 + 22

LLM exécuté en local → aucun CV envoyé à un tiers

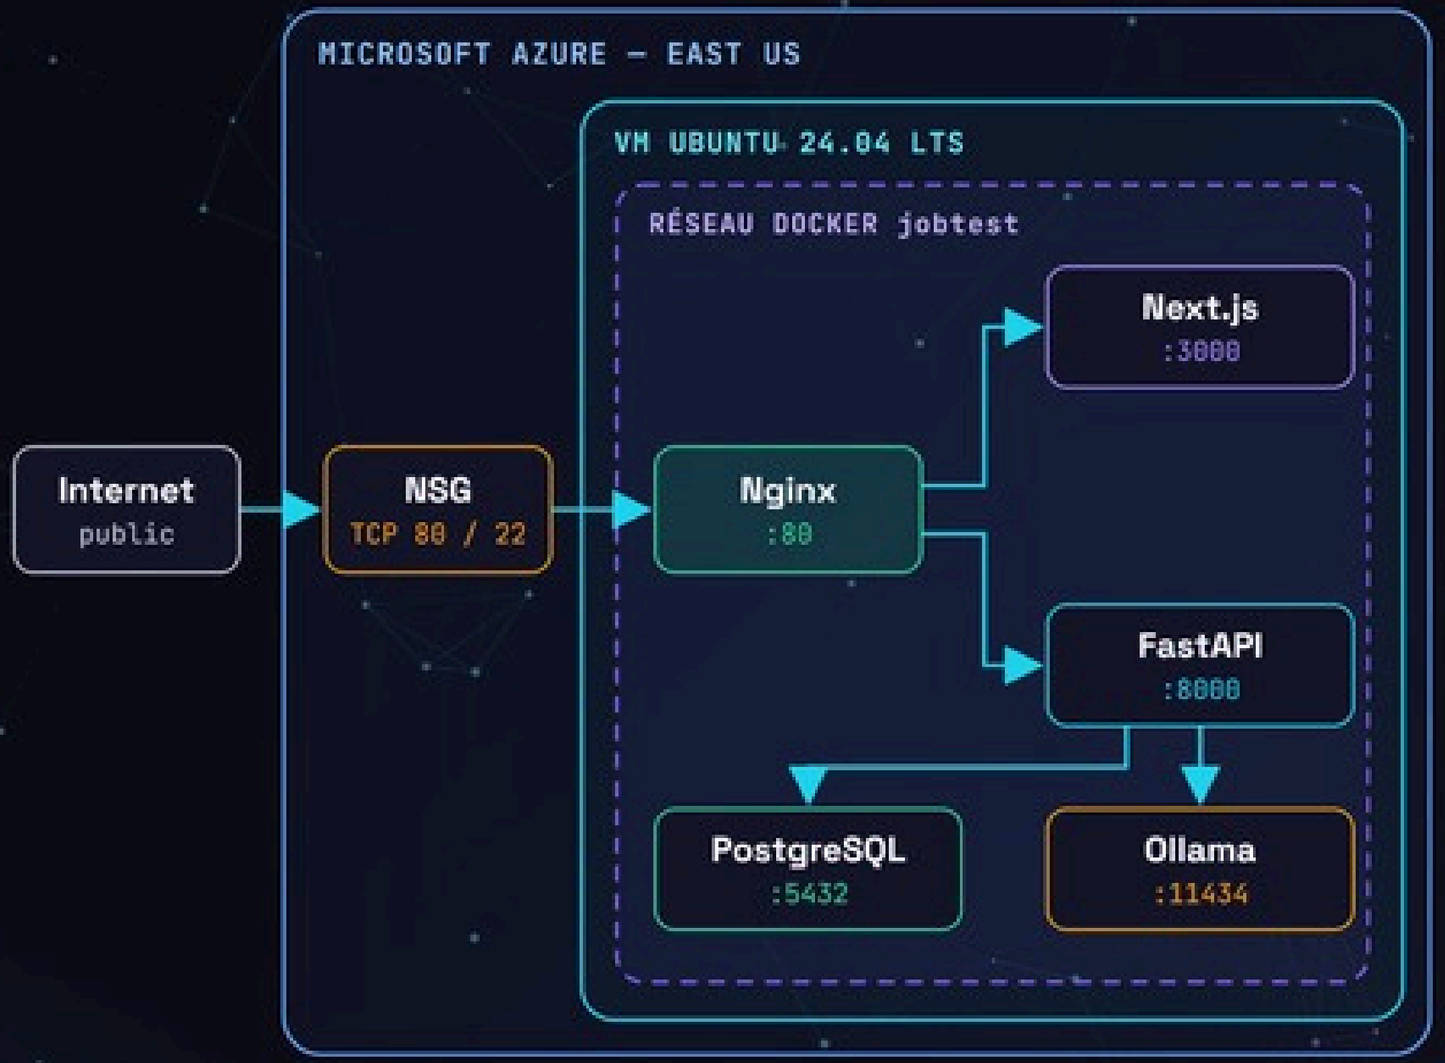
⚠ Limites assumées

- ⚠ HTTP sans TLS
- ⚠ Jeton en `localStorage` (XSS)
- ⚠ SSH à restreindre · UFW inactif
- ⚠ Pas de WAF ni rotation de secrets
- ⚠ Pas de sauvegarde planifiée
- ⚠ Upload validé par extension

Loi tunisienne n° 2004-63 — consentement · finalité · accès · rectification · suppression · INPDP

conditions d'entrée en service

Déploiement Azure : trois frontières emboîtées



VM	vm-jobtest-pfe
Taille	Standard D2as_v7
Ressources	2 vCPU · 8 Gio RAM
Disque	SSD + swap 4 Gio
Coûts	auto-shutdown ~02 h

5 conteneurs — healthy

- nginx:1.27-alpine
- web (build)
- api (build)
- postgres:16-alpine
- ollama/ollama:0.5.13

VOLUMES PERSISTANTS

postgres_data · ollama_data · embedding_cache

— CONCLUSION

Apports du projet : 5 acquis

- **Chaîne complète** CV → verdict → rapport
- **Moteur hybride** 3 signaux documentés
- **Décision explicite** et reproductible
- **Séparation stricte** calcul / génératif
- **Déploiement conteneurisé** démontré sur Azure

— CONCLUSION

Limites & perspectives

HORIZON 1

Court terme

- Domaine + certificat TLS
- Cookies `HttpOnly` / `Secure` / `SameSite`
- Restriction SSH
- Sauvegardes PostgreSQL
- Monitoring
- Correction des tests hérités

HORIZON 2

Moyen terme

- Corpus réel anonymisé & autorisé
- Travail avec des recruteurs
- Enrichir le dictionnaire
- Calibrer les seuils
- Tests de biais
- Évaluation multilingue des explications

HORIZON 3

Long terme

- Traitements asynchrones & file de tâches
- Observabilité
- Intégration ATS
- Gouvernance et audit des décisions assistées

LIMITES ASSUMÉES

⚠ corpus synthétique

⚠ VM unique, pas de HA

⚠ latence CPU de la couche 2

⚠ dictionnaire incomplet

MERCI POUR VOTRE ATTENTION

Place aux questions

DÉMO EN LIGNE · JOBTEST

http://20.51.167.202/